Informe ejecutivo: clasificación de mensajes de Cauce

Destinataria: Laura Benítez

Objetivo

Evaluar si la clasificación automática de mensajes puede reducir derivaciones incorrectas sin aumentar el riesgo de perder avisos de fraude. El modelo principal es Naive Bayes multinomial; KNN se utiliza como comparación.

Evaluación

Los resultados de la tabla corresponden al conjunto de prueba reservado, no utilizado para ajustar los modelos ni elegir los umbrales. La cobertura indica qué proporción se deriva automáticamente; los mensajes restantes requieren revisión humana.

Sistema	Exactitud	F1 macro	Cobertura	Exactitud auto.	Fraude perdido
Naive Bayes	0.939	0.935	0.100	0.975	0.000
KNN	0.923	0.920	0.717	0.974	0.028
Mesa de entrada	0.835	0.824	1.000	0.835	0.335

Regla operativa

Umbrales seleccionados con probabilidades fuera de muestra: P(fraude) ≥ 0.981 fuerza derivación a Fraude; en los demás casos se deriva automáticamente cuando la confianza máxima es ≥ 1.010. Si no se cumplen estas condiciones, se asigna revisión humana. Los umbrales deben aprobarse con los responsables de negocio y riesgo.

Recomendación

Implementar inicialmente en modo asistido, con trasabilidad y revisión humana de mensajes ambiguos. Medir periódicamente cobertura, exactitud automática y fraude perdido; revisar muestras de errores y reentrenar cuando cambie el vocabulario o aparezcan nuevos productos. No automatizar la gestión de fraude sin un umbral de riesgo aprobado.

Impacto diario orientativo

Con 6.500 mensajes diarios, la cobertura observada en prueba equivale aproximadamente a 652 derivaciones automáticas y 5,848 revisiones humanas por día. Es una extrapolación y debe confirmarse con un piloto operacional.